

引文格式:吴雪峰,陈逸智,王昌栋,等.基于深度学习和时空关联建模的降水数据地形订正方法[J].太原理工大学学报,2024,55(4):734-742.

WU Xuefeng, CHEN Yizhi, WANG Changdong, et al. A terrain-based bias-correction method for precipitation data based on deep learning and spatiotemporal correlation modeling[J]. Journal of Taiyuan University of Technology, 2024, 55(4): 734-742.

基于深度学习和时空关联建模的 降水数据地形订正方法

吴雪峰¹, 陈逸智², 王昌栋³, 黄 栋¹

(1. 华南农业大学 数学与信息学院, 广州 510642; 2. 广东省气象数据中心, 广州 510610;
3. 中山大学 计算机学院, 广州 51006)

摘 要:【目的】如何基于地形因素对降水数据进行误差订正(简称“地形订正”)是气象大数据研究的一个重要问题。但是,现有的降水数据地形订正方法存在两方面局限性:一是现有方法大多基于数据统计或传统机器学习而设计,未能拓展至特征学习能力更强的深度学习模型;二是现有方法亦未能结合气象数据的时间与空间关联信息以提升订正效果。【方法】提出一种基于深度学习与时空关联建模的降水数据地形订正方法。该方法首先对广东省降水数据和多源地形信息作预处理,结合经纬度进行对齐与编码,以构建相应的数据矩阵。进而结合各个格点的空间和时间邻域下的降水与地形数据进行多源时空信息建模,并结合降采样策略以缓解降水格点与非降水格点的数据不平衡性,最后构建深度神经网络进行回归订正。实验在广东省逾 4 000 个气象观测站点、逾 15 万气象格点的真实气象数据上进行。【结果】实验结果验证了时空关联建模策略对提升降水订正效果的显著作用以及所提出方法相比于其他对比方法的性能优势。

关键词:气象大数据;深度学习;降水量;地形订正;时空信息

中图分类号:TP181, S161.6 **文献标识码:**A

DOI:10.16355/j.tyut.1007-9432.2023BD010 **文章编号:**1007-9432(2024)01-0734-09

A Terrain-Based Bias-Correction Method for Precipitation Data Based on Deep Learning and Spatiotemporal Correlation Modeling

WU Xuefeng¹, CHEN Yizhi², WANG Changdong³, HUANG Dong¹

(1. College of Mathematics and Informatics, South China Agricultural University, Guangzhou 510642, China;
2. Guangdong Meteorological Data Center, Guangzhou 51010, China; 3. School of Computer
Science and Engineering, Sun Yat-sen University, Guangzhou 510006, China)

Abstract:【Purposes】How to perform bias-correction for precipitation data based on terrain information has been an important problem in meteorological big data research. However, the existing precipitation terrain-based bias-correction methods mostly suffer from two limitations. First, most of them are designed based on statistical models or conventional machine learning

收稿日期:2023-08-30;修回日期:2023-09-26

基金项目:国家自然科学基金资助项目(61976097);广东省气象局科学技术研究资助项目(GRMC2022Q05);广东省气象局协同观测和多源实况数据融合分析技术创新团队资助项目(GRMCTD202103)

第一作者:吴雪峰(1997—),硕士研究生,(E-mail)xfwu@stu.scau.edu.cn;陈逸智(1994—),助理工程师,(E-mail)chenqycyz@126.com
通信作者:黄栋(1987—),副教授,主要从事数据挖掘与大数据分析研究,(E-mail)huangdong06@163.com

models, thus fails to go beyond to the deep learning models with more powerful feature learning ability. Second, they also lack the ability to incorporate the spatiotemporal correlation information in meteorological data for enhancing the bias-correction quality. **【Methods】** To address these limitations, in this paper, a terrain-based bias-correction method for precipitation data based on deep learning and spatiotemporal correlation modeling is presented. First, the precipitation data and multi-source terrain information with alignment and encoding based on the longitude and latitude are preprocessed, and thus the corresponding data matrices are constructed. Then the precipitation and terrain data in the spatial and temporal neighborhood of each grid are adopted to achieve the multi-source spatiotemporal information modeling, and a down-sampling strategy is used to alleviate the imbalance between the precipitation grids and the non-precipitation grids. Finally, the deep neural network is constructed for regression and bias-correction. The experiments are conducted on the real meteorological data from over 4 000 meteorological observation stations and over 150 thousand meteorological grids in Guangdong Province. **【Findings】** Experimental results have verified the significance influence of the spatiotemporal modeling strategy over precipitation bias correction quality and performance advantage of the proposed method over the baseline methods.

Keywords: meteorological big data; deep learning; precipitation; terrain-based bias-correction; spatiotemporal information

随着信息技术的发展,海量数据涌现,国民经济各领域的大数据相关研究与应用日益受到关注^[1]。近年来以深度学习为代表的机器学习方法在气象大数据的多个分支方向上也取得了显著进展^[2-5],但是针对实况气象数据(如降水量、温度)地形订正这一气象领域重要问题的机器学习研究则仍非常有限。在此背景下,本文将聚焦于以深度学习和时空关联建模,解决气象领域的实况降水数据地形订正问题。

降水的形成受一系列复杂因素的影响,其中地形因素也会对降水量的观测与模拟造成很大干扰。对于气象部门,若需要制作降水的实况融合格点产品^[6],这些复杂因素则可能会使融合后数值产生较大的误差。为降低气象数据误差,近年来有不少研究人员考虑选择与降水相关性较大的因素(尤其是地形因素)进行降水订正^[7-9]。但是,现有关于地形因素进行降水订正的方法大多使用基于数理统计的方法,如基于快速傅立叶变换的方法^[10],基于多元线性回归的方法^[11],基于插值的方法^[12],基于概率分布的方法^[13]等。童尧等^[13]对 ResgCM4 模拟的中国区域逐日降水数据建立传递函数进行误差订正,以提高平均降水在夏季和冬季模拟与观测之间的空间相关系数,并减少模拟误差。但是,这些方法往往缺乏自适应学习能力,难以有效应对复杂地形因素的影响,取得的订正效果也较为有限。

考虑到这些局限性,近年来部分研究人员亦尝

试使用机器学习方法对降水数据进行地形订正^[14]。ZHAO et al^[15]基于地形因素和季节降水特征来训练机器学习模型,以此整合不同分辨率、不同时间尺度的多精度、多源降水产品数据,使得降水产品在青藏高原区域的精度得到提高,其中使用了包括 XGBoost(extreme gradient boosting)、朴素贝叶斯(native Bayesian)和多层感知机(multi-layer perceptron)3种不同的机器学习方法。但是,当前基于机器学习的降水地形订正研究仍存在两方面局限性:一方面,仅使用了传统(浅层)的机器学习方法,而未能拓展至特征学习能力更强的深度学习模型以应对更复杂的气象与地形情况;另一方面,在其订正过程中未考虑到气象、地形数据在空间与时间上的关联性,未能结合时间与空间信息更好地进行降水订正。现有方法的这些局限性,也正是本文的降水数据地形订正研究将着力解决的关键瓶颈。

本文以广东省实况降水数据为研究对象,开展降水数据地形订正研究。由于在实际情况下气象观测站不可能覆盖地区的每个角落来对各个气象要素进行观测,因此目前广东省内的降水量等气象要素都是通过有限的观测站观测到的离散数据,再通过气象部门的多源融合产品来模拟出整片区域具有连续性的数据,这种方式必然会造成一定的误差。且由于广东省内的地形复杂,融合产品亦未充分考虑地形对于融合后数据的影响,很可能进一步加剧其

误差。对此,本文基于广东省气象数据中心提供的降水数据,并结合对气象要素有较大影响的多源地形因素(包括坡度、坡向和地表覆盖物等),提出了一种基于深度学习和时空关联建模的降水数据地形订正方法。具体地,本文利用深度神经网络的学习能力,根据并结合地形信息,进一步添加时空信息,达到对降水模拟值进行订正的目的。

本文的算法流程如图 1 所示。首先,获取广东省的 3 类地形数据(坡度、坡向和地表覆盖物)和 2 类降水数据(格点模拟值、站点观测值),结合其经纬

度信息进行对齐与编码,构建相应的数据矩阵。其次,结合各个格点的时间邻域与空间域,对其多源时空信息进行建模,并结合降采样策略以缓解降水格点与非降水格点的数据不平衡性。最后基于深度神经网络对降水数据进行地形订正。本文在广东省真实气象数据上进行了丰富实验,实验结果表明:1) 本文提出的时空关联建模策略可显著提升降水数据地形订正效果;2) 本文算法相比于传统机器学习模型以及其他深度学习模型表现出了更好的地形订正准确性。




图 1 降水数据地形订正算法流程

Fig. 1 Flowchart of terrain correction algorithm for precipitation data

1 基于深度学习和时空信息的降水数据订正

1.1 数据预处理

为实现本文提出的降水数据订正方法,首先需要读取 3 类地形数据和 2 类降水数据,进行数据预处理与经纬度编码。3 类地形数据包括:坡度数据、坡向数据和地表覆盖物数据;2 类降水数据包括:格点(模拟)数据和站点(观测)数据。根据经度和纬度以 0.01° 为间隔,将整个广东省地区分割成棋盘一样一块一块的正方形区域,每个正方形区域称为一个格点,大小为 $1\text{ km} \times 1\text{ km}$ 。其中,格点数据为每个格点的模拟降水值,代表了这片格点区域的降水预测值。站点数据是观测站实际观测的降水值,其在地理上分布是离散的、不均匀的。本文所采用的格点数据和站点数据为广东省内起止时间为 2021 年 7 月 1 日至 2021 年 8 月 31 日的数据。

为将地形数据和降水数据构建成数据集,考虑先将数据处理成各类数据矩阵。但由于经纬度不能

直接对应到矩阵的行和列,因此本文首先对经纬度进行编码,广东省的经度范围大致为 106.55°E 至 119.75°E ,将经度作为矩阵的列并以 0.01° 为间隔进行编号;纬度范围为 17.70°N 至 28.00°N ,将纬度作为矩阵的行并以 0.01° 为间隔进行编号。编码后,只需根据经纬度搜索对应的行或列再将数据写入矩阵相应位置即可。本文建立了 3 类地形矩阵包括坡度矩阵、坡向矩阵和覆盖物矩阵,以及 2 类降水量矩阵包括格点矩阵和站点矩阵,每个数据矩阵的每个位置都是一一对应的,表明其在地理位置上的一致性,且矩阵的每个位置对应一个格点,具有空间位置相对不变性。

1.2 空间与时间邻域信息建模

基于上述过程建立各类数据矩阵,最常规的做法是直接用于生成单格点的数据集。本文将单格点数据集视为空间范围大小为 1×1 和时间窗口大小为 1 的数据集,它表示没有加入任何空间邻域信息和时间序列信息,即使用单格点预测。将每个格点对应的坡度值、坡向值、地表覆盖物值和格点降水

值作为神经网络输入的特征值,而站点降水值作为真实值,通过训练神经网络使得输出的预测值始终

接近于站点降水值。单格点预测示意,如图2(a)所示。




图2 时间与空间邻域示意

Fig. 2 Schematic diagram of time and spatial neighborhood

考虑到格点之间一定空间邻域内具有高度相关性,即相邻区域内地形因素和降水值具有极大的相关性。因此本文为每个格点构建空间邻域信息,从而生成不同空间邻域范围的数据集。为每个格点增加8邻域范围内其他格点的所有信息,包括地形信息和格点降水信息,以此作为数据集的每个样本生成9格点数据集,它的空间范围大小为 3×3 ,时间窗口大小为1。同样地,为每个格点增加24邻域范围内其他格点的所有信息,以此作为数据集的每个样本生成25格点数据集,它的空间范围大小为 5×5 ,时间窗口大小为1。如图2(b)和2(c)所示,分别为8邻域预测和24邻域预测示意图。随着空间范围大小的增加,其外围格点与中间格点的相关性将会逐渐下降,空间范围过大可能会导致引入部分无关信息或冗余信息。为避免增加训练和订正过程的负担,本文选择了两个空间范围大小,分别为 3×3 和 5×5 。

由于格点在短期时间上也具有一定的相关性,因此本文在为每个格点加入空间邻域信息的基础上,更进一步加入每个格点的时间序列信息,以此来增强神经网络训练出模型的准确性和鲁棒性。如图2(d)所示构造的数据集的空间范围大小为 3×3 ,时间窗口为3,即在每个格点加入8邻域范围内其他格点的所有信息的基础上,又加入了该格点及其8邻域范围内其他格点在前两个时刻的所有信息。在本文中,时间窗口大小选择了3和5两种,以此构造了4种类型数据集:1)空间范围大小为 3×3 ,时间窗口大小为3;2)空间范围大小为 3×3 ,时间窗口大小为5;3)空间范围大小为 5×5 ,时间窗口大小为3;4)空间范围大小为 5×5 ,时间窗口大小为5。考虑到时间窗口太小,效果可能不明显,而时间窗口太大则可能会增加神经网络训练负担并影响模型效果,因此本文选择了两个大小适中的时间窗口,分别为3和5。

在整个广东省范围内,从时间线上来看,降雨的

天数和时次都是占少数的,从空间范围上来看,降雨也只是集中在局部地区。因此将会产生大量无降雨的格点,但如果不对无降雨的格点进行降采样的话,生成的数据集绝大部分都是格点降水值和站点降水值皆为零值的样本,如此不仅影响神经网络的训练速度、加大对内存的需求,而且还可能对神经网络训练的效果产生影响。绝大多数为零值的格点降水值和站点降水值,可能将会使得学习出来的模型在实际测试时得到的预测值始终接近于0。由于数据量巨大,表面上看起来训练效果很好,但对于降水值不为0的那部分格点的预测将会始终不准确,而想要预测准确地恰恰是这部分格点。因此本文考虑对无降雨格点进行降采样,以此来提升神经网络训练效果并且大大提升神经网络训练速度。

1.3 深度神经网络实现回归预测

在数据预处理和时空关联建模的基础上,本文进一步利用深度神经网络,将构建好的时空数据集作为输入值来训练模型,从而实现回归预测达到降水订正的目的。使用深度神经网络的优势在于:1)不需要解释数据的含义以及数据之间的关系,完全交于神经网络自己去学习,通过自身的训练来得到某种映射关系,从而输出所期望的预测值;2)浅层的神经网络往往用于解决简单的问题,但对于复杂的问题,则需要深度神经网络将高维数据映射到更低维的空间,最后经过迭代优化获得更加理想的结果。

为此,本文为每种类型数据集都构建了一个由多层全连接神经网络构成的深度神经网络,且每个数据集使用的神经网络结构相同,但输入层的维度、隐藏层的层数以及中间神经元的个数不同。输出层的维度皆为1,输出的预测值即为降水订正值。其中,隐藏层层数和中间神经元个数太少会导致难以提取到有效的特征,但也并非越多越好,层数太多可能会影响神经网络训练速度和收敛速度。因此本文通过不断的测试,将控制隐藏层层数不超过7层,神

经元个数尽量不超过输入维度的 2 倍。

本文将输入的数据样本集合表示为 X , 真实标签集合表示为 Y , 那么 X 和 Y 共同组合成为一个数据集, 网络输出的降水预测值集合表示为 $\hat{Y}$, 则:

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \hat{Y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}. \quad (1)$$

式中: 数据集的每个数据样本 $x_i \in R^d$ 都是 d 维的, d 的大小是由所使用数据集的数据样本维度决定的, 而每个真实标签和预测值 $y_i, \hat{y}_i \in R^1$ 都是 1 维的。让 $Z_0 = X$, 那么:

$$Z^{l+1} = f(W^{l+1}Z^l + b^{l+1}). \quad (2)$$

式中: $l=0, 1, 2, \dots, L-1$; $f(\cdot)$ 为 RELU 激活函数; W^{l+1} 表示第 $l+1$ 层的网络权重; b^{l+1} 表示第 $l+1$ 层的网络偏置值。那么当 $l=L-1$ 时, 即网络最后一层的输出表示为 $Z^L = f(W^L Z^{L-1} + b^L)$, 它也代表了降水预测值, 即 $\hat{Y} = Z^L$ 。

损失函数对于神经网络训练过程具有很大的影响, 它对网络权重的调整起到了关键作用。在 2.7 中, 对于损失函数的选择通过实验进行了分析。在本文中, 网络所使用的损失函数 L_{loss} 选择平均绝对误差 (MAE, E_{MA}):

$$E_{\text{MA}} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|. \quad (3)$$

式中: n 为样本数; y_i 为第 i 个样本的降水真实值; $\hat{y}_i$ 为第 i 个样本通过神经网络模型所输出的降水预测值 (订正后的值)。每轮训练完成都输出 E_{MA} 值, E_{MA} 值越小说明训练出的模型效果越好, 最终保存在训练过程中效果最佳的模型, 且对于神经网络训练好的模型短期内不需要再重新训练。

关于模型的应用过程, 首先通过读取气象数据中心的降水数据接口实时获取降水数据, 该降水数据就是融合产品模拟出的格点降水数据, 对数据经过一些预处理后再加载模型, 使用训练好的网络模型对降水数据进行订正, 最后获取订正后的降水数据并保存。

2 实验结果与分析

在根据空间范围大小和时间窗口大小不同构建的 7 个数据集中进行实验, 并将本文算法和多个传统机器学习算法以及多个深度神经网络模型进行对比分析, 同时, 根据降采样、不同损失函数、不同时空

邻域对实验结果的影响进行了分析。

2.1 数据集与实验设置

以坡度或坡向值存在来作为属于广东省内的范围, 共有 157 834 个格点包含在其中, 而广东省目前只有 4 004 个格点区域存在站点。实验所使用格点降水数据和站点降水数据的起止时间为 2021 年 7 月 1 日至 2021 年 8 月 31 日, 数据是每 1 h 采集一次数据, 所以共有 1 488 个时次的格点降水数据和站点数据。剔除每个时次格点数据中的异常, 同时删除站点数据中的缺测值, 删除这部分缺测值后每个时次可使用的站点数据约在 3 000~3 400 个不等。构建数据集时需使用格点区域内格点降水数据和站点降水数据同时存在的格点。

为了更好地测试模型的有效性, 本文在广东省气象数据中心提供的降水及地形数据上进行实验分析, 以 1.5 个月的数据作为训练集 (并从中划分出验证集), 以 0.5 个月的数据作为测试集。具体地, 以起止时间为 2021 年 8 月 16 日至 2021 年 8 月 31 日的半个月数据作为测试集, 一共 384 个时次格点和站点降水数据文件并且不做任何形式降采样, 测试集的样本总数为 1 171 740, 其中有降雨的格点总数为 66 669, 无降雨的格点总数为 1 106 071。以起止时间为 2021 年 7 月 1 日至 2021 年 8 月 15 日的一个半月数据作为训练集, 一共 1 104 个时次的格点和站点数据。由于无降水格点数据远多于有降水格点数据, 存在数据不平衡问题, 若不经降采样, 数据样本总数将超过 360 万。因此, 本文对训练集的无降水数据进行降采样, 降采样后的数据样本总数为 693 100, 并以 8:2 的比例随机划分为训练集和验证集, 其中有降雨格点总数为 683 100, 无降雨格点总数为 10 000。

本文所有实验都是在 Ubuntu Linux 系统上进行的, 显卡使用的是 12 GB 显存的英伟达 3060, 内存大小 64 GB。所设置的深度神经网络^[16]由多个全连接层构成 (与 ResNet 等其他网络框架的对比分析也将在后续实验中提供), 各层维度大小为 $d-500-500-2\ 000-1$, 其中 d 由数据集的输入样本维度所决定。学习率设置为 0.000 2, Epoch 设置为 200, Batchsize 设置为 100。

2.2 时空邻域设置与评价指标

根据不同空间范围大小和时间窗口大小构造了 7 种不同类型的数据集设置, 其详细情况如表 1 所示, 其中 S1T1 对应于单格点预测, 没有加入任何空间邻域信息和时间序列信息; S3T1 和 S5T1 对应于

空间预测,只加入了空间邻域信息,S3T3、S3T5、S5T3和S5T5对应于时空预测,加入了不同空间邻域大小的信息和不同时间窗口大小的信息。

表1 实验数据集的不同时间与空间邻域设置

Table 1 Different time and spatial neighborhood settings for experimental datasets

数据集	说明	维度
S1T1	空间邻域为 1×1 ; 时间窗口为 1	4
S3T1	空间邻域为 3×3 ; 时间窗口为 1	36
S3T3	空间邻域为 3×3 ; 时间窗口为 3	108
S3T5	空间邻域为 3×3 ; 时间窗口为 5	180
S5T1	空间邻域为 5×5 ; 时间窗口为 1	100
S5T3	空间邻域为 5×5 ; 时间窗口为 3	300
S5T5	空间邻域为 5×5 ; 时间窗口为 5	500

为检验训练模型的有效性,对比不同机器学习方法和不同主干网络的性能,本文采用了两种常用的评价指标,平均绝对误差(MAE, E_{MA})和均方误差(MSE, E_{MS})。MAE的计算公式如式(3)所示,MSE的计算公式如式(4)所示。

$$E_{MS} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2. \quad (4)$$

2.3 深度神经网络回归预测实验结果

本文将数据集划分为训练集、验证集和测试集,训练集和验证集用来训练网络并保存在验证集上效果最好的模型,而最终判断模型的好坏,还是根据其在测试集上的性能。

使用深度神经网络在训练集、验证集和测试集上对比了7种不同类型数据集的实验结果,如表2—4所示。从表中结果来看,本文训练出来的模型得到的预测值误差相对于订正前融合产品模拟降水值误差,在MAE和MSE两个评价标准上都得到了大幅降低。如果单独观察数据集S1T1的实验结果,可以发现地形因素能够有效降低降水预测值的

表2 不同时空邻域下的训练集实验结果对比
(最优得分标红,次优得分标蓝)

Table 2 Comparison of experimental results for different spatial and temporal neighborhoods (the best score is marked in red, and the second-best score is marked in blue)

数据集	MAE			MSE		
	训练集订正前	训练集订正后	降低百分比/%	训练集订正前	训练集订正后	降低百分比/%
S1T1	0.961 472	0.900 967	6.29	7.789 966	7.085 197	9.05
S3T1	0.960 046	0.742 987	22.61	7.743 624	5.403 693	30.22
S3T3	0.962 129	0.736 568	23.44	7.824 925	5.222 504	33.26
S3T5	0.962 442	0.711 874	26.03	7.804 761	4.908 894	37.10
S5T1	0.962 077	0.698 235	27.42	7.774 359	4.690 034	39.67
S5T3	0.962 815	0.674 047	29.99	7.835 906	4.317 484	44.90
S5T5	0.959 791	0.690 784	28.03	7.693 877	4.499 669	41.52

表3 不同时空邻域下的验证集实验结果对比
(最优得分标红,次优得分标蓝)

Table 3 Comparison of validation set experimental results under different spatial and temporal neighborhoods (the best score is marked in red, and the second best score is marked in blue)

数据集	MAE			MSE		
	验证集订正前	验证集订正后	降低百分比/%	验证集订正前	验证集订正后	降低百分比/%
S1T1	0.951 414	0.890 049	6.45	7.446 199	6.836 734	8.18
S3T1	0.957 119	0.757 908	20.81	7.631 569	5.574 163	26.96
S3T3	0.957 624	0.755 087	21.15	7.402 013	5.343 158	27.81
S3T5	0.954 430	0.757 976	20.58	7.482 039	5.570 529	25.55
S5T1	0.948 995	0.734 160	22.64	7.508 629	5.332 251	28.99
S5T3	0.954 878	0.748 733	21.59	7.358 088	5.436 147	26.12
S5T5	0.965 034	0.747 738	22.52	7.925 572	5.522 800	30.32

表4 不同时空邻域下的测试集实验结果对比
(最优得分标红,次优得分标蓝)

Table 4 Comparison of test set experimental results under different spatial and temporal neighborhoods (the best score is marked in red, and the second best score is marked in blue)

数据集	MAE			MSE		
	测试集订正前	测试集订正后	降低百分比/%	测试集订正前	测试集订正后	降低百分比/%
S1T1	0.100 696	0.090 579	10.05	0.863 361	0.750 797	13.04
S3T1	0.100 696	0.077 285	23.25	0.863 361	0.600 479	30.45
S3T3	0.101 140	0.078 888	22.00	0.870 114	0.603 829	30.60
S3T5	0.100 001	0.076 505	23.50	0.860 275	0.614 671	28.55
S5T1	0.100 696	0.076 482	24.05	0.863 361	0.583 568	32.41
S5T3	0.101 140	0.077 587	23.29	0.870 114	0.595 728	31.53
S5T5	0.100 001	0.074 931	25.07	0.860 275	0.581 498	32.41

误差。将坡度、坡向和地表覆盖物等地形因素作为降水订正的重要考量,可以有效减小由于地形因素影响而导致的融合产品预报降水值的不准确性。对比数据集S1T1和其他数据集的实验结果,可以发现加入了不同程度的空间邻域信息和时间序列信息都能够大幅提高降水误差订正效果。特别地,对比数据集S1T1和数据集S5T5在测试集上的结果,MAE降低百分比提升了15.02%,MSE降低百分比提升了19.37%,且数据集S5T5在测试集上的效果要优于所有其他类型数据集。这是因为格点不论是在空间邻域上还是短期时间上都具有高度相关性,为每个格点加入时空信息后能增强预测的准确性和鲁棒性。

2.4 分析降采样对实验的影响

在2.2中,已经讨论过关于无降雨格点对实验的影响,在本节实验中将通过数据不同降采样来具体分析。

对空间范围大小为 5×5 , 时间窗口大小为 5 的数据集类型进行不同程度降采样的实验结果, 如表 5 所示。当只保留 1 万个无降雨格点时, 训练集加上验证集总共约有 69 万条数据样本, 若不进行降采样则会产生 300 多万条数据样本。从表中实验结果来看, 无降雨格点保留多少对总体效果影响不大。

表 5 降采样实验结果和平均训练时间对比

Table 5 Comparison of downsampling experiment results and training time

评价标准 数据集类型	MAE 降低百分比/%			MSE 降低百分比/%			平均每 epoch 训练时间/s
	训练集	测试集	验证集	训练集	测试集	验证集	
S5T5(保留 1 万无降雨格点)	28.03	22.52	25.07	41.52	30.32	32.41	45.704
S5T5(保留 10 万无降雨格点)	27.71	22.20	25.36	42.21	29.82	31.79	51.204
S5T5(保留 100 万无降雨格点)	23.92	20.95	24.60	36.22	30.86	32.23	110.517

2.5 对比不同机器学习算法

将深度神经网络训练得到的结果与多种不同传统机器学习算法进行对比, 其中包括随机森林^[17] (random forest, RF)、支持向量机^[18] (support vector machines, SVM)、决策树 (decision tree, DT)、多元线性回归 (multivariate linear regression, MLR)、套索回归 (lasso regression)、岭回归 (ridge regression) 和极端梯度提升^[19] (extreme gradient boosting, XGboost)。

这些传统机器学习算法虽然在训练集和验证集上的误差都有所降低, 但在测试集上, MSE 降低百分比虽然有所提升, MAE 降低百分比却都呈现出负增长, 即误差不降反增, 如表 6 所示。其相较于深度神经网络训练出的结果还是相差甚远, 这就表明传统机器学习算法不能很好地进行降水订正任务。这是因为以地形因素和降水模拟值作为特征输入时, 传统机器学习算法的特征提取能力有限, 会导致信息流失严重, 不能很好地学习地形因素与降水预测值之间的映射关系。这也是为何在测试集上会出现误差增长的现象。

表 6 机器学习方法对比实验结果 (最优得分加粗)

Table 6 Comparison experiment results of different machine learning methods (bold for the best score)

评价标准 数据集类型	MAE 降低百分比/%			MSE 降低百分比/%		
	训练集	验证集	测试集	训练集	验证集	测试集
随机森林	5.65	2.49	-223.84	19.9	7.83	7.83
支持向量机	4.21	4.25	-2.05	8.66	9.03	14.88
决策树	5.32	1.67	-224.99	17.80	3.41	-3.46
多元线性回归	0.66	0.55	-81.77	8.81	9.25	13.43
套索回归	0.04	0.06	-95.41	9.07	8.14	13.50
岭回归	0.42	0.35	-87.07	9.13	7.98	13.49
极端梯度提升	11.48	4.33	-128.35	21.11	4.47	9.96
本文方法	28.03	22.52	25.07	41.52	30.32	32.41

2.6 对比不同主干网络

以不同的主干网络进行对比实验, 其中包括了

但从平均每个 Epoch 训练时间来说, 降采样程度越大, 完成训练的时间越快, 保留 1 万无降雨格点的训练速度要比保留 100 万无降雨格点快 2 倍多, 并且降采样之后对于内存的需要也大大降低了。

因此, 本文其他实验所使用的所有数据集, 都是只保留了 1 万无降雨格点。

循环神经网络^[20] (recurrent neural network, RNN)、残差网络^[21] (residual network, ResNet) 和长短期记忆网络^[22] (long short-term memory networks, LSTM)。在不同主干网络上进行实验时, 输入数据以及超参的设置包括学习率、Epoch 和 Batchsize 等都是相同的。其中, RNN 和 LSTM 输入数据的时间窗口长度均包含了 1、3 和 5 这 3 个取值来进行实验。

本文对比了 4 种不同神经网络在所有类型数据集上取得的最佳实验结果, 如表 7 所示。由表可以看出, 这四种神经网络对于降水误差的订正都能取得很好的效果。其中 RNN 网络在数据集 S3T1 上取得的订正效果最佳, ResNet 网络在数据集 S3T5 具有最佳的订正效果, 而 LSTM 网络则在数据集 S3T3 上的订正效果是最佳的。这也说明了使用深度学习技术进行降水数据订正比传统机器学习方法更加有效。它们相较于在数据集 S1T1 上取得的订正效果都有了大幅度提升, 因此本文提出的为每个格点增加空间邻域信息和时间序列信息是十分有效的订正方法。

表 7 不同主干网络对比实验结果 (最优得分加粗)

Table 7 Comparison experiment results of different backbone networks (bold for the best score)

评价标准 数据集类型	MAE 降低百分比/%			MSE 降低百分比/%		
	训练集	验证集	测试集	训练集	验证集	测试集
RNN	13.58	13.54	18.17	18.99	21.90	25.80
ResNet	20.18	18.26	19.96	26.98	24.76	29.45
LSTM	21.69	19.49	22.99	31.41	25.41	30.99
本文方法	28.03	22.52	25.07	41.52	30.32	32.41

2.7 不同损失函数的影响

除了不同的网络模型选择外, 损失函数的选择对于网络训练的效果影响也是很大的。若损失函数选择的不好, 则可能起不到任何效果或者起到的效

果很小,因此本文对深度神经网络训练时使用不同的损失函数进行了对比实验,如表8所示。当以MSE作为损失函数时,虽然评价标准MSE大幅降低了,但是评价标准MAE并没有降低,反而误差增大了。若将MAE和MSE同时作为损失函数时,虽然比单独使用MSE作为损失函数的效果有所改善,但相较于单独使用MAE作为损失函数的订正效果反而有所下降。基于上述实验结果,本文选择了MAE作为神经网络的损失函数。

表8 不同损失函数对实验结果的影响
Table 8 Influence of different loss functions on the experimental results

评价标准 数据集类型	MAE 降低百分比/%			MSE 降低百分比/%		
	训练集	验证集	测试集	训练集	验证集	测试集
MAE	28.03	22.52	25.07	41.52	30.32	32.41
MSE	12.45	8.30	-123.04	39.75	26.99	27.50
MAE+MSE	20.78	16.12	13.06	28.18	28.18	30.03

3 结束语

针对气象大数据领域的实况降水数据地形订正问题,提出了一种基于深度学习和时空关联建模的

降水数据订正方法,以解决现有降水地形订正方法欠缺深度特征学习能力、未考虑时空关联信息的局限性。本文首先对降水数据和多源地形数据进行预处理及经纬度编码,以构建结构化的数据矩阵,并考虑气象数据在时间和空间上的高度相关性,加入了时间序列信息和空间邻域信息进行时空关联建模,最后使用深度神经网络进行回归预测。本文实验采用广东省真实气象数据作为数据集,与不同的传统机器学习算法和深度神经网络进行了对比,分析了时空邻域、降采样(数据不平衡)、损失函数等对降水订正性能的影响。实验结果验证了本文方法在降水数据地形订正效果上的显著优势。本文方法通过引入深度学习模型和时空关联信息,突破了气象领域进行实况降水数据地形订正的常规做法,对温度、湿度和气压等其他实况气象数据的订正研究也具有积极的借鉴作用。在未来的研究工作中,一方面将进一步考虑如何结合其他深度神经网络对相关数据集进行更有效训练,例如Transformer等,另一方面也将更深入研究时间与空间信息对实况降水数据地形订正的影响机制。

参考文献:

- [1] YAQOOB I A T, HASHEM A, GANI S, et al. Big data; from beginning to future[J]. International Journal of Information Management, 2016, 36(6): 1231-1247.
- [2] FATHI M, HAGHI K M, JAMEI S M, et al. Big data analytics in weather forecasting; a systematic review[J]. Archives of Computational Methods in Engineering, 2022, 29(2): 1247-1275.
- [3] KLEIN B, WOLF L, AFEK Y. A dynamic convolutional layer for short range weather prediction[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 4840-4848.
- [4] WU Y, TANG Y, YANG X, et al. Graph convolutional regression networks for quantitative precipitation estimation[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 18(7): 1124-1128.
- [5] SHI X, CHEN Z, WANG H, et al. Convolutional lstm network: a machine learning approach for precipitation nowcasting[J]. Advances in Neural Information Processing Systems, 2015: 28.
- [6] 师春香, 潘咏, 谷军霞, 等. 多源气象数据融合格点实况产品研制进展[J]. 气象学报, 2019, 77(4): 774-783.
SHI C X, PAN Y, GU J X, et al. A review of multi-source meteorological data fusion products[J]. Acta Meteorologica Sinica, 2019, 77(4): 774-783.
- [7] 郑婧, 夏侯杰, 陈娟, 等. 基于 ECMWF 模式的定量降水客观订正方法[J]. 高原气象, 2020, 39(4): 830-839.
ZHENG J, XIA H J, CHEN J, et al. Objective correction method for quantitative precipitation forecasting based on ECMWF model[J]. Plateau Meteorology, 2020, 39(4): 830-839.
- [8] 任萍, 陈明轩, 曹伟华, 等. 基于机器学习的复杂地形下短期数值天气预报误差分析与订正[J]. 气象学报, 2020, 78(6): 1002-1020.
REN P, CHEN M X, CAO W H, et al. Error analysis and correction of shortterm numerical weather prediction under complex terrain based on machine learning[J]. Acta Meteorologica Sinica, 2020, 78(6): 1002-1020.
- [9] 张蓓, 戴新刚, 杨阳. 21 世纪前期中国降水预估及其订正[J]. 大气科学, 2019, 43(6): 1385-1398.
ZHANG B, DAI X G, YANG Y. Projection of China precipitation and its bias correction for the early 21st century[J]. Chinese Journal of Atmospheric Sciences, 2019, 43(6): 1385-1398.
- [10] VELASCO-FORERO C A, SEMPERE-TORRES D, CASSIRAGA E F, et al. A non-parametric automatic blending methodology to estimate rainfall fields from rain gauge and radar data[J]. Advances in Water Resources, 2009, 32(7): 986-1002.
- [11] JIA S, ZHU W, LU A, et al. A statistical spatial downscaling algorithm of trmm precipitation based on NDVI and DEM in

- the qaidam basin of China[J]. Remote sensing of Environment, 2011, 115(12): 3069-3079.
- [12] PRASKIEVICZ S, BARTLEIN P. A method for downscaling regional climate model projections of temperature and precipitation using local topographic lapse rates[C]//AGU Fall Meeting Abstracts, 2012: GC11C-1008.
- [13] 童尧, 高学杰, 韩振宇, 等. 基于 RegCM4 模式的中国区域日尺度降水模拟误差订正[J]. 大气科学, 2017, 41(6): 1156-1166.
TONG Y, GAO X J, HAN Z Y, et al. Bias correction of daily precipitation simulated by RegCM4 model over China[J]. Chinese Journal of Atmospheric Sciences, 2017, 41(6): 1156-1166.
- [14] LI H, ZHANG Y, LEI H, et al. Machine learning based bias correction of precipitation measurements at high altitude[J]. Remote Sensing, 2023, 15(8): 2180.
- [15] ZHAO Y, XU K, DONG N, et al. Optimally integrating multi-source products for improving long series precipitation precision by using machine learning methods[J]. Journal of Hydrology, 2022, 609: 127707.
- [16] XIE J, GIRSHICK R, FARHADI A. Unsupervised deep embedding for clustering analysis[C]//International Conference on Machine Learning, 2016: 478-487.
- [17] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45: 5-32.
- [18] CORTES C, VAPNIK V. Support-vector networks[J]. Machine Learning, 1995, 20: 273-297.
- [19] CHEN T, GUESTRIN C. XGboost: a scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining, 2016: 785-794.
- [20] BENGIO Y, SIMARD P, FRASCONI P. Learning longterm dependencies with gradient descent is difficult[J]. IEEE Transactions on Neural Networks, 1994, 5(2): 157-166.
- [21] CHEN D, HU F, NIAN G, et al. Deep residual learning for nonlinear regression[J]. Entropy, 2020, 22(2): 193.
- [22] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

(编辑: 朱 倩)