

DOI: 10.11992/tis.2016030

网络出版地址: <http://www.cnki.net/kcms/detail/23.1538.TP.20160513.0921.020.html>

基于决策加权的聚类集成算法

黄栋¹, 王昌栋^{2,3}, 赖剑煌^{2,3}, 梁云¹, 边山¹, 陈羽¹

(1. 华南农业大学 数学与信息学院, 广东 广州 510640; 2. 中山大学 数据科学与计算机学院, 广东 广州 510006; 3. 广东省信息安全技术重点实验室, 广东 广州 510006)

摘要: 聚类集成的目标是融合多个聚类成员的信息以得到一个更优、更鲁棒的聚类结果。针对聚类成员可靠度估计与加权问题, 提出了一个基于二部图模型与决策加权机制的聚类集成方法。在该方法中, 每个聚类成员被视作一个包含若干连接决策的集合。每个聚类成员的决策集合享有一个单位的可信度, 该可信度由集合内的各个决策共同分享。基于可信度分享的思想, 进一步对各个聚类成员内的决策进行加权, 并将此决策加权机制整合至一个统一的二部图模型; 然后利用快速二部图分割算法将该图划分为若干子集, 以得到最终聚类结果。实验结果表明, 该方法相较于其他对比方法在聚类效果及运算效率上均表现出显著优势。

关键词: 聚类; 聚类集成; 决策加权; 二部图模型; 图分割; 基聚类; 可信度分享; 加权集成

中图分类号: TP18 **文献标志码:** A **文章编号:** 1673-4785(2016)03-0418-08

中文引用格式: 黄栋, 王昌栋, 赖剑煌, 等. 基于决策加权的聚类集成算法 [J]. 智能系统学报, 2016, 11(3): 418-424.

英文引用格式: HUANG Dong, WANG Changdong, LAI Jianhuang, et al. Clustering ensemble by decision weighting [J]. CAAI Transactions on Intelligent Systems, 2016, 11(3): 418-424.

Clustering ensemble by decision weighting

HUANG Dong¹, WANG Changdong^{2,3}, LAI Jianhuang^{2,3}, LIANG Yun¹, BIAN Shan¹, CHEN Yu¹

(1. College of Mathematics and Informatics, South China Agricultural University, Guangzhou 510640, China; 2. School of Data and Computer Science, Sun Yat-sen University, Guangzhou 510006, China; 3. Guangdong Key Laboratory of Information Security Technology, Guangzhou 510006, China)

Abstract: The clustering ensemble technique aims to combine multiple base clusterings to achieve better and more robust clustering results. To evaluate the reliability of the base clusterings and weight them accordingly, in this paper, we propose a new clustering ensemble approach based on a bipartite graph formulation and decision weighting strategy. Each base clustering is treated as a bag of decisions, and is assigned one unit of credit. This credit is shared (divided) by all the decisions in one clustering. Using the credit sharing concept, we propose weighting the decisions in the base clusterings with regard to the credit they have. Then, the clustering ensemble problem is formulated into a bipartite graph model that incorporates the decision weights, and the final clustering is obtained by rapidly partitioning the bipartite graph. Experimental results have demonstrated the superiority of the proposed algorithm in terms of both effectiveness and efficiency.

Keywords: clustering; clustering ensemble; decision weighting; bipartite graph formulation; graph partitioning; base clustering; credit sharing; weighted clustering ensemble

聚类集成 (clustering ensemble) 的目标是融合多个聚类结果以得到一个更优的最终聚类结果^[1-4]。每一个输入聚类称为一个聚类成员 (ensemble mem-

ber) 或者基聚类 (base clustering); 聚类成员可以由不同聚类算法生成, 或者由一个聚类方法在不同参数设定下生成。聚类成员的质量 (或可靠度) 是影响聚类集成性能的关键因素之一。然而, 在无监督设定下, 现有方法大多无法自动评估聚类成员可靠度并据此对其加权, 从而容易受到低质量聚类成员 (甚至病态聚类成员) 的负面影响。近年来, 部分研究者开始对此进行研究并提出了一些加权聚类集成的方法^[5,11], 但是这些方法往往在集成效果和运算效率上仍有局限性。例如, 文献 [1] 提出了一种基

收稿日期: 2016-03-18. 网络出版日期: 2016-05-13.

基金项目: 国家自然科学基金项目 (61573387, 61502543); 广东省自然科学基金杰出青年项目 (16050000051); 广东省自然科学基金博士启动项目 (2016A030310457, 2015A030310450, 2014A030310180); 广东省科技计划项目 (2015A020209124, 2015B010108001); 广州市科技计划项目 (201508010032); 中央高校基本科研业务费专项项目 (16lgzd15); 华南农业大学青年科技人才培养专项基金项目。

通信作者: 王昌栋. E-mail: changdongwang@hotmail.com.

于非负矩阵分解的加权聚类集成方法,但该方法的非负矩阵分解过程运算负担非常大,基本无法应用于大数据集;文献 [8] 提出了一种基于归一化群体认可度指标的加权聚类集成方法,但较高的计算复杂度也是限制其更广泛应用的一个重要障碍。在当前聚类集成研究中,如何高效地对聚类成员的可靠度进行评估并加权集成,仍是一个非常具有挑战性的问题。

针对此问题,本文提出了一种基于二部图构造和决策加权机制的聚类集成算法。我们将每个聚类成员视作一个包含若干连接决策的集合。每个聚类成员的决策集合享有一个单位的可信度,该可信度由集合内的各个决策共同分享。进一步,我们根据每个聚类成员的每个决策分享得到的可信度进行加权,并将之整合至一个二部图模型,进而利用快速二部图分割算法将该图划分为若干块以得到最终聚类结果。我们将本文方法及多个对比方法在 8 个实际数据集上进行实验分析,实验结果表明,本文方法相较于其他对比方法在聚类集成效果及运算效率上均表现出显著优势。

1 相关研究

现有的聚类集成方法,主要可以分为 3 类: 1) 基于点对相似性的方法 [4,5]; 2) 基于图分割的方法 [1,3]; 3) 基于中心聚类的方法 [2,6]。

基于点对相似性的方法 [4,5] 根据数据点与数据点之间在多个聚类成员中属于相同簇的频率来得到一个共联矩阵,并以该共联矩阵作为相似性矩阵,进而采用层次聚类方法得到最终聚类结果。文献 [4] 最早提出共联矩阵的概念,并提出了线索集聚聚类 (evidence accumulation clustering, EAC) 方法。文献 [5] 对 EAC 方法进行扩展,将簇的大小加入考虑,提出了概率集聚算法。

基于图分割的方法 [1,3] 首先根据聚类集成信息构造一个图结构,再利用图分割算法将图划分为若干块,进而得到最终的聚类集成结果。文献 [1] 将聚类集成中的每一个簇视作一条超边,构造得到一个超图结构,进而可使用 METIS 算法 [12] 或 Ncut 算法 [13] 将其分割为若干块,以得到最终聚类结果。

基于中心聚类的方法 [2,6] 将聚类集成问题建模为一个最优化问题,其优化目标是寻找一个与所有聚类成员的相似性最大化的聚类结果。中心聚类问题是一个 NP 难问题 [14],因而在全局聚类空间寻找最优解对于较大的数据集是几乎不可行的。针对此问题,文献 [2] 将聚类表示为染色体,并提出利用遗传算法求得一个近似解。文献 [6] 提出一种基于

2-D 串编码的一致性度量,并利用 0-1 半正定规划来最大化此一致性度量,以得到中心聚类。

尽管国内外研究者已经提出了许多聚类集成算法 [4-6],但这些算法大都将各个聚类成员同等对待,缺乏对聚类成员进行可靠度估计及加权的能力,容易受低质量聚类成员(甚至病态聚类成员)的负面影响。针对此问题,近年来有研究者提出了一些解决方法 [8,11]。文献 [11] 提出了一种基于非负矩阵分解的加权聚类集成方法,在该方法的优化过程中,可对各聚类成员的可靠度进行估计并加权;但是,该方法的非负矩阵分解过程的耗时非常大,使其无法应用于较大数据集。文献 [8] 利用归一化群体认可度指标对各个聚类成员的可靠度进行估计,并进而提出了两个加权聚类集成算法;但是归一化群体认可度指标的计算复杂度较高,使其难以适用于大规模数据的聚类集成问题。在当前聚类集成研究中,如何有效地、高效地估计聚类成员可靠度并据此加权集成,进而提高聚类集成性能,仍是一个亟待解决的挑战性任务。

2 基于决策加权的聚类集成算法

2.1 问题建模

给定一个数据集 $X = \{x_1, x_2, \dots, x_N\}$, 其中 x_i 表示 X 中的第 i 个数据点, N 表示 X 中数据点的个数。令 Π 表示一个包含 M 个聚类成员的集合,记作

$$\Pi = \{\pi^1, \pi^2, \dots, \pi^M\}$$

式中 π^m 表示聚类集合 Π 中的第 m 个聚类成员。每一个聚类成员是对数据集 X 的一个聚类结果,各个聚类成员可以由不同聚类算法得到,或者由一个聚类算法在不同初始化和参数设置下运行得到。每个聚类成员包含若干个簇,记作

$$\pi^m = \{C_1^m, C_2^m, \dots, C_{n^m}^m\}$$

式中: C_i^m 表示聚类成员 π^m 中的第 i 个簇, n^m 表示 π^m 中簇的个数。每个簇是一个包含若干数据点的集合。根据聚类的性质可知,一个聚类成员内所有簇的并集,就是整个数据集,即: $\bigcup_{i=1}^{n^m} C_i^m = X$; 同一个聚类内的任意两个簇之间的交集为空集,即: $\forall i \neq j, C_i^m \cap C_j^m = \emptyset$ 。将全体聚类成员的簇的集合表示为

$$C = \{C_1, C_2, \dots, C_{N_c}\}$$

式中: C_i 表示集合 C 中的第 i 个簇, N_c 表示集合 C 中簇的总数。由其定义可知 $N_c = \sum_{m=1}^M n^m$ 。

聚类集成的目标是将聚类集合 Π 中各聚类成员的信息融合得到一个更优、更鲁棒的聚类结果。根据输入信息的不同,聚类集成问题主要有 2 种不同的建模方式: 第 1 种建模方式同时以聚类集合 Π 和数据集

X 作为输入信息^[15-17];第2种建模方式则只以聚类集合 Π 为输入信息,而不需要访问数据集 X 中的数据特征^[1-4]。两种建模方式的区别就在于除聚类成员的信息之外是否可访问原始数据特征。在聚类集成研究中,第2种建模方式对原始数据的依赖度更低,亦被更广泛采用^[1-4];本文的聚类集成研究按照第2种建模方式进行,即以聚类集合 Π 为输入,不要求访问原始数据特征,依此得到最终聚类结果 π^* 。

2.2 决策加权

在聚类集成问题中,每一个聚类成员可以视作是一个包含若干个连接决策的集合。如果数据点 x_i 和 x_j 在聚类成员 π^m 中被划分在同一个簇,那么我们称 π^m 对 x_i 和 x_j 作出了一个连接决策,由此可得一个簇 $C_k^m \in \pi^m$ 所作出的连接决策的数量为

$$\#Decisions(C_k^m) = \frac{(1 - |C_k^m|) |C_k^m|}{2}$$

式中 $|C_k^m|$ 表示簇 C_k^m 中数据点的个数。进而,可得聚类成员 π^m 所作出的连接决策的数量,即为 π^m 中所有簇的连接决策数之和:

$$\#Decisions(\pi^m) = \sum_{k=1}^{n^m} \#Decisions(C_k^m) \quad (1)$$

每个聚类成员包含一定数量的连接决策;聚类成员的可靠度估计与加权问题,可视作是对聚类成员连接决策的可靠度估计与加权问题。我们在实例研究中发现,聚类成员的可靠度与其连接决策总数存在显著的负相关关系。

具体地,我们以 MNIST 数据集^[18]为例。该数据集包含 5 000 个数据点。我们使用 k 均值聚类算法为该数据集生成 100 个聚类成员,每次生成均采用随机聚类个数及随机初始化。如果两个数据点 x_i 和 x_j 在聚类成员 π^m 中被划分在同一个簇,并且这两个数据点在 MNIST 数据集的真实类别中也属于同一个类,那么称聚类成员 π^m 对数据点 x_i 和 x_j 作出了一个正确决策,并将 π^m 作出的正确决策的数量记作 $\#CorrectDecisions(\pi^m)$ 。我们将聚类成员 π^m 作出的所有连接决策中正确决策所占的比例,称为正确决策率,记作 $RatioCD(\pi^m)$,计算公式为

$$RatioCD(\pi^m) = \frac{\#CorrectDecisions(\pi^m)}{\#Decisions(\pi^m)} \quad (2)$$

图1显示了 MNIST 数据集的 100 个聚类成员的连接决策数与正确决策率之间的关系。对每一个聚类成员,根据式(1)计算其连接决策数,根据式(2)计算其正确决策率,从而在图1中描出对应的坐标点。由图1可以看到,聚类成员的连接决策数与其正确决策率存在显著的负相关关系。此实验结

论的直观理解在于,若一个聚类成员作出的连接决策数量越小(即越稀有),则其正确率往往越高(即越宝贵);若其连接决策数量越大,则其决策出错的比例往往越高。当一个聚类成员将全体数据点都归入同一个簇时,其连接决策数达到最大值,此时该聚类成员的连接决策失去意义。




图1 对于 MNIST 数据集,各聚类成员的连接决策数与正确决策率之间的关系

Fig.1 The relation between #Decisions and RatioCD for the MNIST dataset

一个聚类成员的正确决策率,是其对于数据点两两之间处于同一个簇的判断的正确比例,可视作该聚类成员的可靠度。由于聚类决策数与可靠度的负相关关系,为减小低可靠度决策的不良影响以提高聚类集成鲁棒性,一个可行策略是采取权值与聚类决策数负相关的加权集成方案。在本文中,我们对每个聚类成员分配一个单位的可信度,该可信度由聚类成员内的全体决策共同分享。那么,聚类成员 π^m 中每个连接决策分享到的可信度是 $1/\#Decisions(\pi^m)$ 个单位。根据各个聚类成员中连接决策的平均可信度对其加权,则聚类成员 π^m 的权值计算公式为

$$w(\pi^m) = \frac{\frac{1}{\#Decisions(\pi^m)}}{\sum_{k=1}^M \frac{1}{\#Decisions(\pi^k)}}$$

进而可得:

$$w(\pi^m) = \frac{1}{\#Decisions(\pi^m) \sum_{k=1}^M \frac{1}{\#Decisions(\pi^k)}} \quad (3)$$

由定义可知,全体聚类成员的权值之和为1,即

$$\sum_{m=1}^M w(\pi^m) = 1$$

2.3 二部图构造与聚类集成

在聚类成员可靠度分析与权值分配的基础上,

我们将进一步将聚类集成问题构造为一个二部图模型。在所构造的二部图模型中,聚类集合中各个聚类成员的簇与数据点同时作为节点。簇节点与簇节点之间不存在连接边;数据点节点与数据点节点之间亦不存在连接边。两个节点之间存在连接边,当且仅当其中一个节点是数据点节点,另一个节点是簇节点,并且该数据点位于该簇之内。边的权值由该簇所在的聚类成员的权值决定(见式(3))。由此,可得到一个二部图结构,其左部为数据点节点的集合,右部为簇节点的集合。我们将该二部图结构表示为

$$G = (U, V, E)$$

式中: $U=X$ 表示左部节点集(数据点集合), $V=C$ 表示右部节点集(簇集合), E 表示边的集合。给定两个节点 u_i 和 v_j , 两者之间的边的权值定义为

$$e_{ij} = \begin{cases} w(\pi(v_j)), & u_i \in X, v_j \in C, u_i \in v_j \\ 0, & \text{否则} \end{cases}$$

式中: $\pi(v_j)$ 表示簇 v_j 所在的聚类成员,即如果 $v_j \in \pi^m$, 则 $\pi(v_j) = \pi^m$ 。

接下来,利用图 G 的二部图结构,我们采用 Tcut 算法^[9] 将图 G 快速地分割为若干块,进而将每一块中数据点集合作为最终聚类的一个簇,由此可以得到最终聚类结果。

2.4 时间复杂度

第2.3节所构造的二部图 G 包含有 $N+N_c$ 个节点,其中 N 是数据点个数, N_c 是簇个数。如果使用经典的 Ncut 算法^[9] 对图 G 进行分割,其时间复杂度是 $O(k(N+N_c)^{3/2})$, 其中 k 是图分割的块数。与之相比,本文采用的 Tcut 算法^[9] 可利用图 G 的二部图结构,进行快速图分割,其时间复杂度是 $O(kN+kN_c^{3/2})$; 考虑式(3)中权值计算的复杂度是 $O(N)$, 故本文总体算法的时间复杂度即是 $O(kN+kN_c^{3/2})$ 。由于在实际聚类问题中数据点个数 N 通常远大于簇个数 N_c , 因此使用 Tcut 算法相当于可使时间复杂度由 $O(kN^{3/2})$ 降低至 $O(kN)$ 。当面对大数据集时,本文算法在运算效率上的优势尤其显著;在本文后续的对比实验中,本文聚类集成算法相比于现有算法的效率优势也得到了验证。

3 实验结果与分析

在本节中,我们将在多个实际数据集上进行实验,与若干现有聚类集成算法进行对比分析,以验证本文方法的有效性及其运算效率。

3.1 数据集

本文的实验一共使用了8个实际数据集,分别

是 Glass、Ecoli、Image Segmentation (IS)、MNIST、ISOLET、Pen Digits (PD)、USPS 以及 Letter Recognition (LR)。其中,除 MNIST 数据集来自于文献[8]之外,其他7个数据集均来自于 UCI 机器学习数据仓库 (UCI machine learning repository)^[24]。所用的测试数据集的具体情况如表1所示。

表1 实验数据集

Table 1 Description of datasets

数据集	数据点数	维度	类别数
Glass	214	9	7
Ecoli	336	7	8
IS	2 310	19	7
MNIST	5 000	784	10
ISOLET	7 797	617	26
PD	10 992	16	10
USPS	11 000	256	10
LR	20 000	16	26

3.2 实验设置与评价指标

在本文实验中,我们首先需要生成一个包含若干聚类成员的聚类集合,以对比分析本文方法以及其他聚类集成方法的聚类效果。具体地,我们在每一次运行中使用 k 均值聚类算法生成 M 个聚类成员,每一个聚类成员的生成均采用随机初始化,并在区间 $[2, \sqrt{N}]$ 中随机选取初始聚类个数 k 。对于每一个方法在每一个数据集上的实验,我们均运行10次(每次使用随机生成的聚类集合,如前所述),然后得到各个方法的平均性能得分,以实现客观公平的对比与分析。

我们将聚类成员个数 M 称为聚类集成规模;将数据集的数据点数 N 称为数据规模。在后续实验中,我们首先固定聚类集成规模 $M=10$, 接下来分别进行本文方法与聚类成员以及与其他聚类集成方法的对比实验,并进一步测试在不同聚类集成规模 M 下各个聚类集成方法的聚类表现。最后,将对对比测试各个聚类集成方法的运算效率。在本文实验中,采用标准互信息量 (normalized mutual information, NMI)^[10] 作为评价指标。NMI 可根据两个聚类之间的互信息量来度量其相似性,是聚类研究中被广泛应用的一个评价指标。一个聚类结果(与真实聚类比较)的 NMI 值越大,则表示其聚类质量越好。

3.3 与聚类成员的对比实验

聚类集成的目标是融合多个聚类成员的信息以期得到一个更优聚类。在本节中,我们将本文方法的聚类集成结果,与聚类成员进行对比实验。在每

个数据集上均测试 10 次; 每次测试均随机生成一个包含 M 个聚类成员的聚类集合, 然后在此聚类集合上运行本文算法以得到一个集成聚类结果。由此, 得到本文方法在 10 次运行测试中的平均表现以及聚类成员的平均表现(以 NMI 度量)。如图 2 所示。




图 2 本文方法与聚类成员的性能对比

Fig.2 Comparison between our method and the base clusterings

本文方法可取得比聚类成员更好的聚类结果; 尤其是在 Glass、Ecoli、IS、MNIST、PD、

USPS 等数据集, 本文方法相较聚类成员优势更显著。

3.4 聚类集成方法的对比实验

本节将所提出方法与 6 个现有的聚类集成方法进行对比实验。这 6 个对比方法分别是 evidence accumulation clustering (EAC)^[4]、hybrid bipartite graph formulation (HBGF)^[5]、SimRank similarity based method (SRS)^[21]、weighted connected triple based method (WCT)^[22]、weighted evidence accumulation clustering (WEAC)^[8] 以及 graph partitioning with multi-granularity link analysis (GP-MGLA)^[8]。

在每一个数据集中, 每个聚类集成方法均运行 10 次, 每次运行根据第 3.2 节所述随机生成聚类成员, 进而得到每个算法在每个数据集的平均 NMI 得分及其标准差。在表 2 中, 在每一个数据集中, 最高 NMI 得分以粗体显示。如表 2 所示, 本文方法在 8 个数据集上均取得了优于其他聚类集成方法的聚类效果, 特别是在 Glass、MNIST 和 USPS 数据集上, 本文方法取得的平均 NMI 得分比其他方法高出 10% 左右。表 2 的对比实验结果验证了本文方法在聚类集成效果上的优势。

表 2 本文方法与其他聚类集成方法的对比实验
Table 2 The average performances of different methods

测试方法	Glass	Ecoli	IS	MNIST	ISOLET	PD	USPS	LR
本文方法	0.463	0.682	0.641	0.653	0.756	0.787	0.632	0.454
EAC ^[4]	0.418	0.640	0.618	0.592	0.746	0.747	0.580	0.435
HBGF ^[5]	0.397	0.635	0.624	0.609	0.747	0.757	0.588	0.441
SRS ^[21]	0.423	0.632	0.623	0.594	0.747	0.755	0.593	0.436
WCT ^[22]	0.434	0.678	0.623	0.627	0.752	0.764	0.598	0.439
WEAC ^[8]	0.409	0.637	0.616	0.607	0.746	0.752	0.581	0.439
GP-MGLA ^[8]	0.399	0.640	0.634	0.624	0.747	0.758	0.602	0.441

3.5 在不同聚类集成规模下的对比实验

接下来, 我们进行本文方法与其他对比方法在不同聚类集成规模(即聚类成员个数)下的对比实验。当聚类集成规模由 $M = 10$ 增长到 50 时, 各个聚类集成方法在 10 次运行中的平均 NMI 得分如图 3 所示。在 Ecoli 数据集中, WCT 方法取得了与本文方法基本相当的性能表现。除了 Ecoli 数据集之外, 在其他 7 个数据集中, 本文方法在不同聚类集成规模下的聚类表现均显著优于其他方法。图 3 的实验结果验证了本文方法在不同聚类集成规模下表现出比其他聚类集成方法更好的鲁棒性。


3.6 运行时间

在本节中, 我们进行各个聚类集成方法的运行时


间对比实验。所有实验均在 MATLAB 2014b 下运行, 所使用的工作站配置具体如下: Windows Server 2008 R2 64 位操作系统; 英特尔八核心 2.4 GHz 中央处理器; 96 GB 内存。为求客观对比各个算法运行的 CPU 时间, 所有实验均在单线程模式下运行。

为测试各个聚类集成算法在不同数据规模(即数据点个数)下的运行时间, 本节实验在 LR 数据集的不同大小的子集上进行。LR 数据集一共包含有 2 万个数据点; 我们在实验中所测试的子集大小从 0 逐步增长至 20 000。例如, 当测试数据规模设定为 $N' \in [0, 20\ 000]$ 时, 我们就随机从整个 LR 数据集中选取 N' 个数据点进行实验, 并记录各个测试方法在此数据规模上的运行时间。如图 4 所示, 当数据规模较小


时,HBGF、EAC、WEAC 以及本文方法均有较高运算效率。而当数据规模继续增长时,本文方法相对于其他方法的效率优势开始变大。对于整个 LR 数据集 20 000 个数据点的规模,本文方法仅需要 6.19 s; 除本文方法之外,其他对比方法之中最快的 3 个方法 (HBGF、EAC 和 WEAC) 则分别需要 12.18、34.48 和 33.87 s 的运算时间。图 4 验证了本文方法的优势。




(a) Glass




(b) Ecoli




(c) IS




(d) MNIST




(e) ISOLET



(f) PD



(g) USPS



(h) LR

图3 各个方法的聚类集成性能

Fig.3 The performances of different clustering ensemble methods with varying ensemble sizes




图4 各个聚类集成方法在不同数据规模下的运行时间对比

Fig.4 Execution time of different methods with varying data sizes

3 结束语

为解决聚类集成研究中的聚类成员可靠度估计与加权问题,本文提出了一个基于二部图结构与决策加权机制的聚类集成方法。我们将每个聚类成员视为一个包含若干连接决策的集合,并为每个聚类成员的决策集合分配一个单位的可信度。该可信度由聚类成员内的各个决策共同分享。进一步地,我们提出基于可信度分享的决策加权机制,并将之整合至一个统一的二部图模型中。因其二部图结构,该图模型可利用 T_{cut} 算法进行快速分割,从而得到最终聚类集成结果。本文在8个实际数据集中进行了实验,将所提出方法与聚类成员以及6个现有方法进行了对比分析。实验结果验证了本文方法在聚类质量及运算效率上的显著优势。

参考文献:

- [1] STREHL A, GHOSH J. Cluster ensembles—a knowledge reuse framework for combining multiple partitions [J]. The journal of machine learning research, 2003, 3(3): 583-617.
- [2] CRISTOFOR D, SIMOVICI D. Finding median partitions using information-theoretical-based genetic algorithms [J]. Journal of universal computer science, 2002, 8(2): 153-172.
- [3] FERN X Z, BRODLEY C E. Solving cluster ensemble problems by bipartite graph partitioning [C] //Proceedings of the 21st International Conference on Machine Learning. New York, NY, USA, 2004.
- [4] FRED A L N, JAIN A K. Combining multiple clusterings u-

- sing evidence accumulation [J]. IEEE transactions on pattern analysis and machine intelligence, 2005, 27(6): 835-850.
- [5] WANG Xi, YANG Chunyu, ZHOU Jie. Clustering aggregation by probability accumulation [J]. Pattern recognition, 2009, 42(5): 668-675.
- [6] SINGH V, MUKHERJEE L, PENG Jiming, et al. Ensemble clustering using semidefinite programming with applications [J]. Machine learning, 2010, 79(1/2): 177-200.
- [7] HUANG Dong, LAI Jianhuang, WANG Changdong. Exploiting the wisdom of crowd: a multi-granularity approach to clustering ensemble [C] //Proceedings of the 4th International Conference on Intelligence Science and Big Data Engineering. Beijing, China, 2013: 112-119.
- [8] HUANG Dong, LAI Jianhuang, WANG Changdong. Combining multiple clusterings via crowd agreement estimation and multi-granularity link analysis [J]. Neurocomputing, 2015, 170: 240-250.
- [9] HUANG Dong, LAI Jianhuang, WANG Changdong. Ensemble clustering using factor graph [J]. Pattern recognition, 2016, 50: 131-142.
- [10] HUANG Dong, LAI Jianhuang, WANG Changdong. Robust ensemble clustering using probability trajectories [J]. IEEE transactions on knowledge and data engineering, 2016, 28(5): 1312-1326.
- [11] LI Tao, DING C. Weighted consensus clustering [C] //Proceedings of the 2008 SIAM International Conference on Data mining. Auckland, New Zealand, 2008: 798-809.
- [12] KARYPIS G, KUMAR V. Multilevel k-way partitioning scheme for irregular graphs [J]. Journal of parallel and distributed computing, 1998, 48(1): 96-129.
- [13] NG A Y, JORDAN M I, WEISS Y. On spectral clustering: Analysis and an algorithm [C] //Advances in Neural Information Processing Systems. Vancouver, Canada, 2001.
- [14] TOPCHY A, JAIN A K, PUNCH W. Clustering ensembles: models of consensus and weak partitions [J]. IEEE transactions on pattern analysis and machine intelligence, 2005, 27(12): 1866-1881.
- [15] VEGA-PONS S, CORREA-MORRIS J, RUIZ-SHULCLOPER J. Weighted partition consensus via kernels [J]. Pattern recognition, 2010, 43(8): 2712-2724.
- [16] VEGA-PONS S, RUIZ-SHULCLOPER J, GUERRA-GANDÓN A. Weighted association based methods for the combination of heterogeneous partitions [J]. Pattern recognition letters, 2011, 32(16): 2163-2170.
- [17] 徐森, 周天, 于化龙, 等. 一种基于矩阵低秩近似的聚类集成算法 [J]. 电子学报, 2013, 41(6): 1219-1224.

XU Sen, ZHOU Tian, YU Hualong, et al. Matrix low rank

approximation-based cluster ensemble algorithm [J]. Acta electronica sinica, 2013, 41(6): 1219-1224.

[8] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[9] LI Zhenguo, WU Xiaoming, CHANG S F. Segmentation using superpixels: a bipartite graph partitioning approach [C] // Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition. Providence, RI, USA, 2012: 789-796.

[10] BACHE K, LICHMAN M. UCI machine learning repository [EB/OL]. (2013-04-04). <http://archive.ics.uci.edu/ml>.

[11] IAM-ON N, BOONGOEN T, GARRETT S. Refining pairwise similarity matrix for cluster ensemble problem with cluster relations [C] // Proceedings of the 11th International Conference on Discovery Science. Budapest, Hungary, 2008: 222-233.

[12] IAM-ON N, BOONGOEN T, GARRETT S, et al. A link-based approach to the cluster ensemble problem [J]. IEEE transactions on pattern analysis and machine intelligence, 2011, 33(12): 2396-2409.

作者简介:



黄栋,男,1987年生,讲师,主要研究方向为数据挖掘与模式识别,发表学术论文10余篇。



王昌栋,男,1984年生,讲师,主要研究方向为非线性聚类、社交网络、大数据分析,发表学术论文40余篇。



赖剑煌,男,1964年生,教授,博士生导师,博士,广东省图象图形学会理事长,中国图象图形学会常务理事,主要研究方向为生物特征识别、数字图像处理、模式识别和机器学习。主持国家自然科学基金与广东联合重点项目、科技部科

技支撑课题各1项,主持国家自然科学基金项目4项。发表学术论文近200篇。

全国知识图谱与语义计算大会 China Conference on Knowledge Graph and Semantic Computing (CCKS2016)

全国知识图谱与语义计算大会(CCKS: China Conference on Knowledge Graph and Semantic Computing)由中国中文信息学会语言与知识计算专家委员会负责组织和承办。CCKS2016源于国内两个主要的相关会议:中文知识图谱研讨会 Conference on Chinese Knowledge Graph (KG) 和中国语义互联网与 Web 科学大会 Chinese Semantic Web and WebScience Conference (CSWS)。首届中文知识图谱研讨会于2013年在苏州举行,随后分别在武汉、宜昌成功举办第二次和第三次研讨会。CSWS首次会议于2006年在北京举办,随后的近十年里,逐渐成为国内语义技术领域的主要会议。新的知识图谱与语义计算大会将致力于成为国内知识图谱、语义技术、链接数据等领域的核心会议,并聚集了知识表示、自然语言处理、机器学习、数据库、图计算等相关领域的重要学者和研究人员。

今年会议的主题是“语义、知识与链接大数据”。今年会议的主题是“语义、知识与链接大数据”。会议将包括学术讲习班、工业界论坛、评测与竞赛、特邀报告、学术论文、海报及演示等主要环节。其中,学术讲习班邀请国内外知名研究者讲授实学术界最新进展和实战经验,工业界论坛邀请产业界的主要研发人员分享经验,促进产学研合作。

大会同时欢迎英文和中文论文。英文论文将被 Springer 出版的论文集收录,中文论文将被推荐到东南大学学报、中文信息学报等期刊发表。部分优秀论文将被推荐到 the Semantic Web Journal, Elsevier Journal of Big Data Research, Journal of Web Semantics 等国际期刊发表。所有论文要求是未发表内容,并通过会议论文网站提交: <https://easychair.org/conferences/?conf=ccks2016>。相关主题如下(但不限于):

- | | |
|----------------|-----------------|
| 1) 知识表示 | 5) 知识共享与基于知识的系统 |
| 2) 知识图谱构建与信息抽取 | 6) 知识推理 |
| 3) 语义集成 | 7) 链接数据 |
| 4) 知识存储 | |

会议网站: <http://ccks2016.cipsc.org.cn/> 或 <http://ccks2016.cn>